



# مفاهیم پیشرفته در یادگیری ماشین

نیم سال دوم ۱۴۰۱-۱۴۰۰

مدرس: دکتر مهدیه سلیمانی

زمان تحویل: ۲۵ اسفندماه

عنوان تمرین

تمرین سری دوم

لطفا نکات زیر را رعایت کنید:

- سوالات خود را از طریق پست مربوط به تمرین در Quera مطرح کنید.
- در هر کدام از سوالات، اگر از منابع خاصی استفاده کرده‌اید باید آن را ذکر کنید.
- پاسخ ارسالی واضح و خوانا باشد.
- تمام پاسخ‌های خود را در یک فایل با فرمت zip [Fullname]\_[SID]\_HW# روی کوثر قرار دهید.
- برای ارسال هر تمرین تا ساعت ۲۳:۵۹ روز ددلاین فرصت دارید. علاوه بر آن، در هر تمرین می‌توانید تا سقف هفت روز از تأخیر مجاز باقیمانده‌ی خود استفاده کنید.
- برای کسب نمره کامل در این تمرین کفایت ۱۶۰ نمره را دریافت نمایید، ما بقی نمرات امتیازی می‌باشند (۴۰ نمره امتیازی).

## سوال ۱: متا-یادگیری مبتنی بر بهینه‌سازی دو سطحی

همانطور که در جلسات درس مشاهده کرده‌اید، یکی از روش‌های متا-یادگیری، خانواده بهینه‌سازی دو سطحی بوده که مهمترین کار در این زمینه روش MAML می‌باشد. در این خانواده از روش‌ها، متا-پارامترها (پارامترهای آهسته) هم بعد با پارامترهای مختص وظیفه (پارامترهای سریع) بوده و به عنوان یک نقطه شروع برای آن‌ها عمل می‌کنند. به طور دقیق‌تر، اگر توزیع وظایف (Tasks) را به صورت  $p(T)$  در نظر بگیریم، می‌توان رابطه زیر را برای یادگیری متا-پارامترها ارائه داد:

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{T=(S,Q) \sim p(T)} [\mathcal{L}(\phi, Q)] \quad (1)$$

$$\text{Where } \phi = \text{Alg}(\theta, S) \quad (1b)$$

که در این رابطه  $S$  مجموعه داده‌های پشتیبان (Support) و  $Q$  مجموعه داده‌های پرسمان (Query) مربوط به هر وظیفه (Task) را نشان می‌دهد. در این رابطه، محاسبه پارامترهای سریع  $\phi$  توسط روش Alg انجام می‌شود که در مقالات مربوطه به طرق مختلفی انتخاب شده و بهینه‌سازی داخلی (Inner-Level) نامیده می‌شود. همچنین در رابطه فوق، بهینه‌سازی خارجی (Outer-Level) که روی پارامترهای  $\theta$  صورت می‌پذیرد، به شکل  $\arg \min$  نمایش داده شده است. برای انجام بهینه‌سازی خارجی، لازم است تا از تابع معرفی شده نسبت به  $\theta$  گرادیان را به صورت زیر محاسبه کرده و  $\theta$  را از طریق آن به‌روزرسانی نماییم:

$$\nabla_{\theta} \mathbb{E}[\mathcal{L}(\phi, Q)] = \mathbb{E}[\nabla_{\theta} \mathcal{L}(\text{Alg}(\theta, S), Q)] \quad (2)$$

برای محاسبه عبارت فوق، از قاعده زنجیره‌ای مشتق استفاده می‌کنیم:

$$\nabla_{\theta} \mathcal{L}(\text{Alg}(\theta, S), Q) = \nabla_{\phi} \mathcal{L}(\phi, Q)|_{\phi=\text{Alg}(\theta, S)} \times \frac{d}{d\theta} \text{Alg}(\theta, S) \quad (3)$$

همانطور که مشاهده می‌کنید، رابطه فوق از دو جمله تشکیل شده است؛ محاسبه جمله اول نسبتاً راحت است. چرا که کفایت تا از  $\mathcal{L}$  مشتق گرفته و مقدار  $\text{Alg}(\theta, S)$  را در آن جایگذاری کنیم و در این صورت گرادیانی از  $\text{Alg}(\theta, S)$  عبور نمی‌کند. این در حالیست که برای محاسبه جمله دوم، لازم است تا عملیات مشتق‌گیری را از داخل الگوریتم  $\text{Alg}(\theta, S)$  عبور دهیم. این مسئله می‌تواند مشکل‌زا باشد چرا که ممکن است  $\text{Alg}(\theta, S)$  اصلاً قابلیت عبور گرادیان را نداشته باشد یا اگر دارد ممکن است منجر به محاسبات پرهزینه شود. به عنوان مثال، در روش MAML داریم:

$$\text{Alg}(\theta, S) = \theta - \alpha \nabla_{\theta} \mathcal{L}(\theta, Q) \Rightarrow \frac{d}{d\theta} \text{Alg}(\theta, S) = I - \alpha \nabla_{\theta}^2 \mathcal{L}(\theta, S) \quad (4)$$

که در رابطه فوق، محاسبه مشتق‌های مرتبه دوم (Hessian) می‌تواند بسیار سخت یا پرهزینه باشد چرا که لازم است تا کل گراف محاسباتی در طول مسیر محاسبه  $\text{Alg}(\theta, S)$  نگه داشته شود تا بتوان گرادیان را از روی آن عبور داده و به مراحل قبلی رساند.

در این سوال قصد داریم تا تکنیکی معرفی کنیم که با استفاده از آن این مشکلات مرتفع شوند. برای این منظور، فرض کنید  $\text{Alg}(\theta, S)$  به صورت زیر پیشنهاد شده است:

$$\phi = \text{Alg}(\theta, S) = \arg \min_{\phi'} \mathcal{L}(\phi', S) + \frac{\lambda}{2} \|\phi' - \theta\|^2 \quad (5)$$

که  $\lambda$  یک هایپرپارامتر است و هر چه مقدار آن بیشتر باشد، باعث می شود تا جواب بهینه سازی درونی، به نقطه شروع خود یعنی  $\theta$  نزدیک تر بماند. بهینه سازی ۵ را می توان با انجام چندین گام بهینه سازی تکرار شونده (Iterative) حل کرد اما مشکل آن جاست که امکان عبور گرادیان از چنین محاسباتی وجود ندارد. با در نظر گرفتن این مسئله، به پرسش های زیر پاسخ دهید:

(آ) فرض کنید ما قادر هستیم تا بهینه سازی ۵ را به صورت کامل حل کنیم و  $\phi$  را به عنوان جواب بهینه دقیق آن به دست آورده ایم. از این مسئله استفاده کنید و  $\frac{d\phi}{d\theta}$  را محاسبه کنید (راهنمایی: در نقطه بهینه دقیق، مشتق  $\mathcal{L}(\phi', S) + \frac{\lambda}{2} \|\phi' - \theta\|^2$  نسبت به  $\phi'$  صفر خواهد بود).

(ب) اگر مراحل پرسش قبل را به درستی طی کرده باشید، در جواب خود به یک عبارت حاوی مشتق مرتبه دوم  $\nabla^2 \mathcal{L}$  (یا همان ماتریس Hessian) می رسید. محاسبه این عبارت چه تفاوتی با مشتق مرتبه دوم موجود در رابطه ۴ دارد؟ استفاده از این تابع  $\text{Alg}$  پیشنهادی چه مزیتی نسبت به MAML دارد؟

(ج) به عنوان جمع بندی، الگوریتمی که متا-یادگیر در هر اپیزود طی می کند را به صورت گام گام شرح دهید.

پاسخ

(آ)

$$\frac{d}{d\phi'} \mathcal{L}(\phi', S) + \frac{\lambda}{2} \|\phi' - \theta\|^2 = \nabla_{\phi'} \mathcal{L}(\phi', S)|_{\phi'=\phi} - \lambda(\phi' - \theta)|_{\phi'=\phi} = 0 \quad (6\text{آ})$$

$$\Rightarrow \phi = \theta - \frac{1}{\lambda} \nabla_{\phi} \mathcal{L}(\phi, S) \quad (6\text{ب})$$

$$\Rightarrow \frac{d}{d\theta} \phi = I - \frac{1}{\lambda} \nabla_{\phi}^2 \mathcal{L}(\phi, S) \times \frac{d\phi}{d\theta} \quad (6\text{ج})$$

$$\Rightarrow \frac{d\phi}{d\theta} = (I + \frac{1}{\lambda} \nabla_{\phi}^2 \mathcal{L}(\phi, S))^{-1} \quad (6\text{د})$$

(ب) مشتق مرتبه دوم به دست آمده در الگوریتم MAML به صورت  $\nabla_{\theta}^2 \mathcal{L}(\theta, S)$  می باشد این در حالیکه در روش معرفی شده با محاسبه  $\nabla_{\phi}^2 \mathcal{L}(\phi, S)$  مواجه می شویم. این بدان معناست که مشتق دوم مورد نظر، کافیت در نقطه بهینه حاصل از حل دقیق بهینه سازی ۵ نوشته شود و به مسیری که در گام های محاسبه ۵ طی شده است، هیچ وابستگی وجود ندارد. توجه کنید که  $\theta$  همان نقطه شروع بهینه سازی است در حالی که  $\phi$  نقطه نهایی بهینه سازی محسوب می شود. لذا در حل ۵ کافیت تا گرادیان  $\theta$  و  $\phi$  را قطع کنیم، بهینه سازی ۵ را حل کرده و گرادیان مورد نیاز برای آپدیت  $\theta$  را با کمک روابط ۳ و ۶ به دست آوریم. این در حالیکه در رویکرد MAML (مخصوصاً زمانی که بیش از یک گام بهینه سازی در حلقه داخلی بر می داریم)، لازم است تا کل گراف محاسباتی و کل وزن های محاسبه شده در میان مسیر را نگه داری کنیم تا بتوانیم مشتق های مرتبه دو را محاسبه کنیم.

(ج) • یک وظیفه (Task) به صورت  $\mathcal{T} \in D_{\text{meta-train}}$  نمونه برداری می کنیم که شامل داده های پشتیبان  $S$  (Support) و پرسمان  $Q$  (Query) می باشد.

• با در دست داشتن داده های  $S$ ، بهینه سازی ۵ را با روش های مرسوم بهینه سازی انجام می دهیم و حاصل را  $\phi$  می نامیم.

• طبق رابطه ۶ مشتق  $\phi$  نسبت به  $\theta$  را محاسبه می کنیم.

• با کمک داده های  $Q$ ، عبارت  $\nabla_{\phi} \mathcal{L}(\phi, Q)|_{\phi=\text{Alg}(\theta, S)}$  را محاسبه می کنیم.

• از ضرب دو رابطه محاسبه شده در دو مورد اخیر،  $\nabla_{\theta} \mathcal{L}(\text{Alg}(\theta, S), Q)$  را محاسبه کرده و با کمک این گرادیان متا-پارامترهای  $\theta$  را آپدیت می کنیم.

## سوال ۲: روش های مبتنی بر یادگیری متریک

روش های یادگیری متریک یکی دیگر از روش هایی هستند که در درس به عنوان یکی از اعضای خانواده متا-یادگیری با آن ها آشنا شدید. در این روش ها هدف آن است که یک شبکه استخراج ویژگی مثل  $f_{\theta}(x)$  یاد گرفته شود تا داده های کلاس یکسان را در فضای نمایش مخفی در کنار یکدیگر تصویر کند. پارامترهای  $\theta$  متا-پارامترهای مدل در نظر گرفته می شوند در طول متا-یادگیری آموزش داده می شوند. از آنجایی که  $f_{\theta}(x)$  صرفاً یک فضای نمایشی (Representation Space) فراهم می کند، برای کامل کردن شبکه نیاز به یک دسته بند (یادگیر پایه) پارامتریک یا نان-پارامتریک داریم که روی این فضای نمایشی قرار گرفته، از داده های پشتیبان برای آماده سازی خود استفاده کرده و با کمک آن ها عمل دسته بندی نمونه های

پرسیمان را انجام دهد. پارامترهای دسته‌بند معرفی شده را به عنوان پارامترهای سریع می‌شناسند و آن‌ها را با  $\phi$  نمایش می‌دهند. این پارامترها مختص هر وظیفه به دست آمده و برای وظیفه بعدی تغییر می‌کنند. در این روش‌ها یکی از تصمیمات مهم در زمینه طراحی الگوریتم انتخاب مناسب همین دسته‌بند می‌باشد. از جمله انتخاب‌های موجود برای این خانواده، انتخاب روش Nearest Neighbour می‌باشد. همچنین روش دیگری که در مقاله ProtoNet معرفی شد استفاده از دسته‌بندهای مبتنی بر پروتوتایپ دسته‌ها (با میانگین گیری از داده‌های موجود در مجموعه پشتیبان از هر کلاس) می‌باشد. مشکلی که متایادگیری مبتنی بر پروتوتایپ دارند این است که دسته‌بند ساده‌ای دارند و تعمیم‌پذیری دسته‌بند در فاز متا-ارزیابی کم می‌باشد. به همین دلیل در مقاله Bertinetto 2018 به بررسی دو دسته‌بند رایج در یادگیری ماشین (Logistic Regression, Ridge Regression) و نحوه استفاده موثر آن در مسئله متایادگیری پرداخته است. با مطالعه مقاله و راهنمایی‌های داده شده در زیر، به سوالات پاسخ دهید

(آ) توضیح دهید که در نگاه اول، استفاده از این دسته‌بندها چه مشکلی می‌تواند برای فرایند متا-آموزش ایجاد کند؟ چرا استفاده از رویکردهای پروتوتایپی یا KNN این مشکل را ایجاد نمی‌کند؟ (راهنمایی: پاسخ این مورد غیر مرتبط با پرسش قبل نیست)

(ب) توضیح دهید که در مقاله معرفی شده، چگونه مشکل معرفی شده را حل می‌کند؟ تفاوت رویکردی که برای Ridge Regression و Logistic Regression به کار گرفته می‌شود را توضیح دهید.

(ج) دو ماتریس  $X \in \mathbb{R}^{n \times d}$  و  $Y \in \mathbb{R}^{n \times l}$  را در نظر بگیرید که  $n$  تعداد داده‌ها و  $d$  اندازه بردار بازنمایی هر داده و  $l$  تعداد برچسب‌های موجود در دسته می‌باشد. ثابت کنید که دو رابطه زیر در صورتی که  $\lambda > 0$  باشد، با هم برابر می‌باشند و نحوه استفاده آن در دسته‌بند Ridge Regression را توضیح دهید:

$$(X^T X + \lambda I)^{-1} X^T Y = X^T (X X^T + \lambda I)^{-1} Y$$

(د) توضیح دهید که برای انجام متایادگیری استفاده از کدام یک از دو رابطه بالا بهتر می‌باشد و چرا؟

(ه) در مقاله معرفی شده، برای محاسبه وزن‌های دسته‌بند Logistic Regression از بهینه‌سازی با روش Newton استفاده شده است. دلیل این امر را بیان کنید و همچنین در مورد خود Newton's Method تحقیق کنید و رابطه به روزرسانی و نحوه بدست آوردن این رابطه را بنویسید.

(و) تعاریف زیر را در نظر بگیرید:

$$\begin{aligned} A_t &= \text{diag}(q_t) \\ q_t^{(i)} &= \sigma(\omega_t^T x^{(i)}) (1 - \sigma(\omega_t^T x^{(i)})) \\ B_t^{(i)} &= \sigma(\omega_t^T x^{(i)}) - y^{(i)} \end{aligned}$$

که  $A \in \mathbb{R}^{n \times n}$  یک ماتریس قطری و  $B \in \mathbb{R}^n$  می‌باشد.

با اعمال Newton's Method روی تابع هزینه این دسته‌بند، به رابطه به‌روزرسانی زیر که مشابه رابطه ۷ مقاله می‌باشد برسید. (رابطه ۷ مقاله خود دارای اشکالات Notation ای بود)

$$\omega_{t+1} = (X^T A_t X + \lambda I)^{-1} (X^T A_t X \omega_t - X^T B_t)$$

پاسخ:

(آ) دو دسته‌بند ذکر شده، دسته‌بندهایی پارامتریک هستند و برای آن که پارامترهای آن‌ها محاسبه شود، نیاز است تا یک دستگاه بهینه‌سازی حل شود. یکی از روش‌های حل دستگاه، استفاده از رویکردهای iterative و استفاده مستقیم از رویکرد Gradient Decent است. بدی استفاده از این نوع Solver آن است که مراحل انجام شده در رویکرد iterative قابلیت عبور گرادیان را ندارند و این باعث به مشکل خوردن متا-یادگیری می‌شود. به عبارت دقیق‌تر، فرض کنید که نمونه‌های پشتیبان را از شبکه استخراج ویژگی عبور داده‌اید و آن‌ها را در فضای نمایشی تعبیه کرده‌اید. سپس با یک رویکرد iterative بهینه‌سازی مربوط به Ridge Regression را انجام داده و وزن‌های دسته‌بند را به دست می‌آورید. مشکلی که وجود دارد آن است که نمی‌توان گرادیان Meta-Loss را از وزن‌های به دست آمده عبور داد و از طریق آن شبکه استخراج ویژگی و پارامترهای  $\theta$  را آپدیت کرد. این در حالیست که با استفاده از KNN، به راحتی می‌توان وزن‌های  $\theta$  را آپدیت کرد چرا که دسته‌بند مستقیماً با خود نمونه‌های هر کلاس کار می‌کند. با استفاده از این رویکرد می‌توان گرادیان را از نمونه‌های موجود هر کلاس عبور داد و از این طریق چینش نمونه‌های یک کلاس را طوری تنظیم کرد که نمونه‌های یک کلاس در فضای نمایش نزدیک یک دیگر بیفتند. رویکرد مشابهی در مورد دسته‌بند پروتوتایپی وجود دارد چرا که عملیات میانگین‌گیری روی نمونه‌های یک کلاس مشکلی برای عبور مسیر گرادیان ایجاد نمی‌کند و با آپدیت کردن  $\theta$  می‌توان نمونه‌ها را طوری در فضا تعبیه کرد که نمونه‌های مربوط به یک کلاس خاص در نزدیکی پروتوتایپ کلاس خودشان قرار بگیرند.

(ب) این مقاله برای حل مشکل Ridge Regression، به جای حل iterative آن، یک جواب Closed-form به عنوان وزن‌های بهینه معرفی می‌کند. این جواب بسته به راحتی قابلیت عبور گرادیان به لایه‌های عقبی را فراهم می‌کند.

از سویی برای دسته‌بند Logistic Regression، از رویکرد iterative خاصی استفاده می‌کند و همزمان نشان می‌دهد که این رویکرد قابلیت عبور گرادیان از تک تک مراحل iterative را فراهم می‌کند. رویکرد مورد استفاده Newton's Method نام دارد.

(ج) باتوجه به اینکه ماتریس  $Y$  در هردو طرف مساوی از سمت راست در معادله ضرب شده است، پس تنها کافی است که اثبات کنیم:

$$(X^T X + \lambda I)^{-1} X^T = X^T (X X^T + \lambda I)^{-1}$$

برای شروع اثبات در رابطه زیر را در نظر بگیرید:

$$\lambda X^T = \lambda X^T$$

ماتریس همانی را برای یک سمت از رابطه مساوی بالا از سمت چپ ماتریس  $X^T$  و یک بار از سمت راست ماتریس، ضرب می‌کنیم:

$$\lambda I_d X^T = \lambda X^T I_n$$

حال عبارت  $X^T X X^T$  را به دو سمت مساوی اضافه می‌کنیم.

$$X^T X X^T + \lambda I_d X^T = X^T X X^T + \lambda X^T I_n$$

با فاکتورگیری داریم:

$$(X^T X + \lambda I_d) X^T = X^T (X X^T + \lambda I_n)$$

حال اگر در دو طرف تساوی، عبارت  $(X^T X + \lambda I_d)^{-1}$  را از چپ و عبارت  $(X X^T + \lambda I_n)^{-1}$  را از سمت راست ضرب کنیم داریم:

$$(X^T X + \lambda I_d)^{-1} (X^T X + \lambda I_d) X^T (X X^T + \lambda I_n)^{-1} = (X^T X + \lambda I_d)^{-1} X^T (X X^T + \lambda I_n) (X X^T + \lambda I_n)^{-1}$$

با ساده‌سازی داریم:

$$X^T (X X^T + \lambda I_n)^{-1} = (X^T X + \lambda I_d)^{-1} X^T$$

که مطلوب سوال می‌باشد.

این نکته لازم به ذکر می‌باشد که ماتریس‌هایی که معکوس آن را در اثبات بالا استفاده کردیم هردو ماتریس‌های مثبت نیمه‌معین می‌باشند و بنابراین حتماً معکوس‌پذیر می‌باشند.

رابطه معرفی شده، همان جواب Closed-Form برای دسته‌بند Ridge Regression است و همانطور که مشاهده می‌شود، در محاسبه این وزن‌ها تنها از ضرب ماتریسی و معکوس‌گیری استفاده شده است که این اپراتورها قابلیت عبور گرادین از خود را فراهم می‌کنند.

(د) برای انجام متیادگیری استفاده از رابطه  $X^T (X X^T + \lambda I_n)^{-1}$  بهینه‌تر می‌باشد. چون در این رابطه نیاز به محاسبه معکوس یک ماتریس با ابعاد  $n \times n$  داریم ولی در حالت دیگر نیاز به محاسبه معکوس ماتریسی به ابعاد  $d \times d$  می‌باشد که مقدار  $d$  که بیانگر ابعاد بازنمایی در شبکه عصبی می‌باشد که به مراتب خیلی بزرگتر از تعداد نمونه‌ها در مسئله‌های متیادگیری می‌باشد چرا که که تعداد نمونه‌های پشتیبان در مسائل few-shot خیلی کم می‌باشد.

(ه) به دلیل محدودیت تعداد به‌روزرسانی پارامترها در حلقه درونی الگوریتم، از Newton's Method برای همگرایی سریع‌تر به نسبت گرادین‌گیری ساده استفاده شده است. در Newton's Method علاوه بر گرادین، اطلاعات مشتق دوم نیز استفاده می‌شود. توجه کنید که در تابع هزینه‌های محدب (از جمله همین Logistic Regression) استفاده از این رویکرد می‌تواند خیلی سریع ما را به نقطه بهینه همگرا کند. در این روش با نوشتن بسط Taylor حول یک نقطه داریم:

$$f(x+t) = f(x) + f'(x)t + \frac{f''(x)t^2}{2}$$

در رابطه بالا برای کمینه کردن مقدار تابع، نسبت به پارامتر  $t$  که جهت به‌روزرسانی و حرکت می‌باشد مشتق می‌گیریم که جهت بهینه به‌روزرسانی را پیدا کنیم:

$$\frac{dy}{dx} \left( f(x) + f'(x)t + \frac{f''(x)t^2}{2} \right) = f'(x) + f''(x)t = 0$$

$$t^* = -\frac{f'(x)}{f''(x)}$$

(و) هدف سوال کمینه‌کردن منفی لگاریتم بیشینه درست‌نمایی به همراه یک جمله منظم‌سازی می‌باشد.

$$P(Y|\omega, X) = \prod_{i=1}^N \left( \sigma(\omega^T x^{(i)}) \right)^{y^{(i)}} \left( 1 - \sigma(\omega^T x^{(i)}) \right)^{1-y^{(i)}}$$

$$L = -\log P(Y|\omega, X) + \lambda \|\omega\|^2 = -\sum_{i=1}^N \left[ y^{(i)} \log \left( \sigma(\omega^T x^{(i)}) \right) + (1 - y^{(i)}) \log \left( 1 - \sigma(\omega^T x^{(i)}) \right) \right] + \lambda \|\omega\|^2$$

حال با گرادینان گیری مقادیر گرادینان اول و دوم را حساب می‌کنیم:

$$\nabla_{\omega} L = \sum_{i=1}^N \left( \sigma \left( \omega^T x^{(i)} \right) - y^{(i)} \right) x^{(i)T}$$

$$\nabla_{\omega}^2 L = \sum_{i=1}^N \sigma \left( \omega^T x^{(i)} \right) \left( 1 - \sigma \left( \omega^T x^{(i)} \right) \right) x^{(i)T} x^{(i)}$$

حال اگر سیگماهای بالا را به ضرب ماتریسی تبدیل کنیم، طبق رابطه به‌روزرسانی داریم:

$$\begin{aligned}\omega_{t+1} &= \omega_t - H^{-1} \nabla L \\ &= \omega_t - (X^T A_t X + \lambda I)^{-1} (X^T B_t + \lambda \omega_t) \\ &= (X^T A_t X + \lambda I)^{-1} ((X^T A_t X + \lambda I) \omega_t - X^T B_t - \lambda \omega_t) \\ &= (X^T A_t X + \lambda I)^{-1} (X^T A_t X \omega_t - X^T B_t) \\ \omega_{t+1} &= (X^T A_t X + \lambda I)^{-1} (X^T A_t X \omega_t - X^T B_t)\end{aligned}$$

### سوال ۳: (نظری) تنظیم توزیع برای یادگیری چندنمونه‌ای (۴۰ نمره)

یکی از ریسک‌های احتمالی در یادگیری چندنمونه‌ای احتمال بیش برآزش بر روی دادگان کم‌تعداد آموزشی است. در این مقاله روشی پیشنهاد شده است تا به کمک استخراج مشخصات آماری کلاس‌های حاضر در متآموزش بتوان توزیع دادگان کلاس‌های حاضر در متانتست را تنظیم کرد. این مقاله را به دقت خوانده و به سوالات زیر به طور کامل پاسخ دهید:

(آ) از آنجایی که ممکن است توزیع دادگان هر کلاس حاضر در متآموزش گاوسی نباشد و دارای مقداری کشیدگی باشد؛ در نظر گرفتن این توزیع‌ها به عنوان توزیع گاوسی و استخراج میانگین و کواریانس از آن‌ها می‌تواند اشتباه باشد. توضیح دهید این مقاله چه روشی را برای حل مشکل کشیدگی توزیع دادگان متآموزش اتخاذ کرده است و چگونه این روش موجب حل مشکل کشیدگی توزیع می‌شود؟

(ب) پس از استخراج میانگین و کواریانس کلاس‌های حاضر در متآموزش، مدل ارائه شده اقدام به تنظیم توزیع دادگان حاضر در متانتست می‌کند. به صورت کامل و با نوشتن روابط ریاضی مربوطه بیان کنید این تنظیم توزیع به چه صورت انجام می‌پذیرد و وجود کلاس‌های مشابه در متانتست به کلاس منظور در متانتست چه کمکی به تنظیم توزیع می‌کند؟

(ج) در تنظیماتی که در هنگام متانتست از هر کلاس بیش از یک نمونه آموزش داشته باشیم این مدل به جای میانگین‌گیری از نمونه‌ها، برای هر کدام از  $k$  نمونه آموزش اقدام به تنظیم توزیع جداگانه می‌کند. توضیح دهید توزیع تنظیم جداگانه چه مزیتی نسبت به میانگین‌گیری نمونه‌ها و سپس یک توزیع تنظیم دارد؟

### سوال ۴: (عملی) یادگیری چندنمونه‌ای از طریق یادگیری متریک (۴۰ نمره)

در این سوال قصد داریم تا مدل یادگیرنده شبکه **Prototypical** را مورد پیاده‌سازی و بررسی قرار دهیم. به این منظور هر دو زیر مجموعه‌های آموزش و تست دادگان CIFAR100 را دریافت کرده و سپس آن‌ها را به یکدیگر الحاق نمایید. سپس این دادگان را به سه زیر مجموعه متآموزش، متاعتبارسنجی و متانتست تقسیم کنید. به این صورت که دادگان آموزش شامل ۷۰ کلاس، دادگان اعتبارسنجی شامل ۲۰ کلاس و دادگان کلاس تست شامل ۱۰ دیگر باشند. در گام بعدی بایستی یک **Sampler** پیاده‌سازی کنید که با گرفتن پارامترهای **Way** و **Shot** بتواند دادگان اتکا و پرسمان برای یک وظیفه را تولید کند (در واقع این ماژول با هر فراخوانی دو مجموعه داده به اندازه  $Way * Shot$  برای اتکا و پرسمان خروجی می‌دهد). این ماژول در واقع هر بار یک اپیزود را تولید میکند. در طی آزمایش‌های زیر از ماژول **ProtoNetBack** که در فایل‌های پیوستی قرار داده شده است به عنوان شبکه تکیه استخراج ویژگی استفاده کنید و در جلوی آن دو لایه متصل با اندازه دلخواه قرار دهید.

(آ) دسته‌بند را با تنظیمات 8-shot, 10-way آموزش دهید و سپس دقت مدل را بر روی دادگان متانتست گزارش دهید. انتظار می‌رود دقت در این بخش بیشتر از ۵۰ درصد باشد.

(ب) به ازای هر یک از تنظیمات  $shot \in \{1, 2, 4, 8, 16\}$  و 10-way آزمایش بالا را تکرار کرده و نمودار دقت متانتست بر حسب shot را رسم نمایید.

(ج) حال به ازای هر یک از تنظیمات  $way \in \{2, 4, 8, 16, 32\}$  و 5-shot آزمایش را تکرار کرده و نمودار دقت متانتست بر حسب way را رسم نمایید. (دقت کنید که در هنگام متانتست از تنظیمات 5-shot, 10-way استفاده نمایید)

(د) حال در هنگام متاآموزش با تنظیمات 10-shot, 10-way دسته‌بند را آموزش دهید. در هنگام متاتست اما متاتست را به ازای هر یک از تنظیمات  $shot \in \{1, 5, 10, 15, 20\}$  انجام دهید و نمودار دقت آن را بر حسب shot رسم نمایید.

#### سوال ۵: (عملی) متیادگیری براساس بهینه‌سازی (۴۰ نمره)

در این سوال قصد داریم تا مدل معروف دسته متیادگیری براساس بهینه‌سازی، MAML، را پیاده‌سازی نماییم. مقاله مرتبط با این کار، [این مقاله](#) می‌باشد. در Notebook داده شده تمام پارامترهای مسئله و مراحل حل به صورت گام به گام تشریح شده است. سوال از دو بخش اصلی تشکیل شده است که در بخش اول به دلیل کاهش هزینه آموزش بخش عمده شبکه به صورت pretrained شده در اختیار شما قرار داده شده است و شما تنها روی بخش مشخص شده شبکه فرایند متیادگیری را انجام خواهید داد. در بخش اول قرار است تاثیر تعداد گام‌های به‌روزرسانی مدل در حلقه داخلی الگوریتم، مورد بررسی قرار گیرد. از شما خواسته شده است که به ازای مقادیر ۱ تا ۳ این مورد را انجام دهید و نتیجه هر حالت را مقایسه و گزارش کنید. در بخش دوم نیز از شما خواسته شده است که حال با یک گام به‌روزرسانی حلقه داخلی، کل ساختار مدل (مدل متیادگیری بخش اول + ساختار مدل pretrained داده شده) را به صورت متاپارامتر در نظر بگیرید و متیادگیری را روی آن انجام دهید. در نهایت نتایج بدست آمده از هر دو بخش را تحلیل و گزارش نمایید.